

## Exercício 2 - Redes Neurais Artificiais

---

A.P. Braga

Agosto de 2020

### 1 PROBLEMA NÃO-LINEARMENTE SEPARÁVEL

- Objetivos: melhor entendimento do papel das projeções não-lineares na linearização de problemas em redes neurais artificiais.
- Considere o problema de classificação não-linear da Figura 1, que representa amostras duas classes, representadas na figura nas cores vermelha e preta. Um classificador capaz de separar amostras das duas classes deve resultar em uma superfície que separe as duas regiões. Funções que poderiam resolver este problema são, por exemplo, são funções radiais, circulares ou mesmo aproximações com múltiplas retas que resultem na separação das duas regiões. Composições de retas formando uma região hexagonal englobando a classe preta, por exemplo, pode resultar em uma boa separação. Pede-se que seja implementada, em R, Python ou outra linguagem de sua preferência, uma projeção não linear arbitrária que torne o problema linearmente separável. Apresente o gráfico final da superfície de separação. Tente trabalhar com uma ou duas funções somente para que o resultado da projeção possa ser visualizado. Apresente o gráfico dos pontos projetados neste novo espaço.




Figure 1: Pontos em vermelho pertencem à classe positiva e pontos em preto pertencem à classe negativa

Os dados foram gerados em R a partir da seguinte rotina:

```
x = seq(-1,1,by = 0.1)
y = seq(-1,1,by = 0.1)
create_grid <- expand.grid(x,y)

circle <- function(x,y) {
  return(sqrt(x^2+y^2))
}

raio = 0.6

classe = 1*(circle(create_grid$Var1,create_grid$Var2)>raio)
```

## 2 OVERFITTING E UNDERFITTING

- Objetivos: Entendimento dos conceitos de *overfitting* e *underfitting* e sua relação com a dimensão do modelo e erros de treinamento e teste.
- Considerando-se a Figura 2, que apresenta os dados de treinamento para um problema de regressão:
  - Qual dos 3 modelos construídos (preto, vermelho e azul) parece ser a melhor aproximação da função geradora dos dados, sabendo-se que existe um ruído na amostragem?
  - Qual dos modelos apresenta menor erro de treinamento?
  - Qual dos modelos deve ter melhor desempenho para dados novos?
  - Discuta sobre os efeitos do dimensionamento do modelo e ajuste aos dados (erro de treinamento) sobre a aproximação de funções com dados amostrados,

como o da figura. Baixo erro de treinamento implica em melhor desempenho no longo prazo? Discuta.




Figure 2: Ajuste de três modelos para um problema de regressão

### 3 APROXIMAÇÃO POLINOMIAL

#### INTRODUÇÃO TEÓRICA

Considere um polinômio de grau  $p$  conforme representado na sua forma geral na Equação 1.

$$p(x) = w_p x^p + w_{p-1} x^{p-1} + \cdots + w_1 x + w_0 \quad (1)$$

em que  $x$  é o argumento e  $w_i$  é o coeficiente do termo de grau  $i$ .

Dadas as observações  $(x_i, y_i)$  representadas na forma do conjunto de dados  $D = \{x_i, y_i\}_{i=1}^N$ , deseja-se encontrar o polinômio de grau  $p$  que melhor aproxima a função geradora  $f_g(x)$  do conjunto  $D$ . O objetivo é, a partir das amostras de dados, encontrar o grau  $p$  e os coeficientes  $w_i$  de forma tal que  $p(x) \approx f_g(x) \forall x$ . A aproximação de  $f_g(x)$  é usualmente feita com base na minimização do erro dos termos quadráticos  $(y_i - p(x_i))^2$  ( $i = 1 \cdots N$ ). Espera-se que o conjunto  $D$  contenha informação suficiente para que seja possível aproximar  $f_g(x)$  por  $p(x)$  com base somente nas suas  $N$  amostras. Os parâmetros de  $p(x)$  são ajustados de forma tal que  $y_i = w_p x_i^p + w_{p-1} x_i^{p-1} + \cdots + w_1 x_i + w_0 \forall x_i \in D$ , conforme representado no sistema de equações 2.

$$\begin{array}{cccccc} y_1 = & w_p x_1^p & + w_{p-1} x_1^{p-1} & + & \cdots & + w_1 x_1 & + w_0 \\ y_2 = & w_p x_2^p & + w_{p-1} x_2^{p-1} & + & \cdots & + w_1 x_2 & + w_0 \\ \vdots & \vdots & \vdots & \cdots & \vdots & & \\ y_N = & w_p x_N^p & + w_{p-1} x_N^{p-1} & + & \cdots & + w_1 x_N & + w_0 \end{array} \quad (2)$$

O sistema representado em 2 possui  $N$  equações e  $p$  incógnitas, podendo também ser representado na forma matricial 3.

$$\mathbf{H}\mathbf{w} = \mathbf{y} \quad (3)$$

em que  $\mathbf{H}$ ,  $\mathbf{w}$  e  $\mathbf{y}$  são representados em 4, 5 e 6.

$$\mathbf{H} = \begin{bmatrix} x_1^p & x_1^{p-1} & \cdots & x_1 & 1 \\ x_2^p & x_2^{p-1} & \cdots & x_2 & 1 \\ \vdots & \vdots & \cdots & \vdots & \vdots \\ x_N^p & x_N^{p-1} & \cdots & x_N & 1 \end{bmatrix} \quad (4)$$

$$\mathbf{w} = \begin{bmatrix} w_p \\ w_{p-1} \\ \vdots \\ w_1 \\ w_0 \end{bmatrix} \quad (5)$$

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} \quad (6)$$

A matriz  $\mathbf{H}$  possui um papel importante na resolução do problema de aproximação, pois ela contém os termos não-lineares que compõem o polinômio  $p(x)$ , os quais serão responsáveis pela projeção dos elementos  $x_i$  no espaço composto pelo sistema de coordenadas caracterizado pelas colunas de  $\mathbf{H}$ . Como  $\mathbf{H}$  e  $\mathbf{y}$  são dados pelo problema, a solução da Equação 3 pode ser obtida por meio da pseudoinversa, conforme Equação 7.

$$\mathbf{w} = \mathbf{H}^+ \mathbf{y} \quad (7)$$

em que  $\mathbf{H}^+$  é a pseudoinversa de  $\mathbf{H}$ .

## EXERCÍCIOS

Considerando a aproximação polinomial das seções anteriores, faça:

- Obtenha aproximações polinomiais a partir de 10 amostras da função geradora  $f_g(x) = \frac{1}{2}x^2 + 3x + 10$  somadas com um ruído gaussiano  $N(mean = 0, sd = 4)$  amostradas entre  $x = -15$  e  $x = 10$ , com um número de amostras  $N = 20$  e grau do polinômio variando entre  $p = 1$  a  $p = 8$ . Para cada aproximação, mostre um gráfico com a função geradora, as amostras e o polinômio obtido.
- Responda: Ocorreu Overfitting? Ocorreu Underfitting? Em quais casos ocorreu estes fenômenos?

- Repita o procedimento para 100 amostras ao invés de 10. Qual o impacto do número de amostras na aproximação polinomial?

Para o cálculo da pseudo-inversa o aluno deverá usar o pacote *library("corpcor")*.

**Instruções:** O exercício deve ser entregue em formato *pdf* via moodle. Recomenda-se a utilização de ferramentas como R markdown, Sweave ou Jupyter Notebook (ou similares), para elaboração dos relatórios.